Рекомендации датасаентистам и аналитикам:

«Выбор эффективных средств визуализации данных»

Контекст документа: материал разработан для курса «Интеллектуальный анализ и визуализация данных» (треки *BI-аналитики* / Qlik Sense и *ML-инжиниринга* / Taipy). Для сквозного кейса предметной области используется датасет сортировки (триажа) алертов SIEM аналитиками центра мониторинга информационной безопасности (SOC).

Оглавление

Введение 2
1 Ресурсы по визуализации данных 2
2 Базовый алгоритм выбора диаграммы 3
3 Матрица выбора специфических диаграмм Data Science 5
4 Исследовательский анализ данных (EDA) и проверка распределений 5
4.1 Гистограмма (Histogram) [Универсально: Qlik, Taipy] 6
4.2 Квантиль-квантильный график (QQ Plot) [трек ML: Taipy/Python] 6
4.3 График оценки плотности ядра (KDE Plot) [трек ML: Taipy/Python] 7
4.4 Скрипичная диаграмма (Violin Plot) [трек ML: Taipy/Python] 8
4.5 Облачная диаграмма распределения (Raincloud Plot) [трек ML: Taipy/Python] 9
5 Оценка качества ML-моделей и объяснимый ИИ (XAI) 10
5.1 ROC-кривая vs. Кривая точности-полноты (PR Curve) [Универсально: Qlik, Taipy] 10
5.2 График значений Шепли (SHAP Summary / Waterfall Plot) [трек ML: Taipy/Python] 11
5.3 График частичной зависимости (Partial Dependence Plot (PDP)) 11
5.4 График смещения-дисперсии (Bias-Variance Plot) [трек ML: Taipy/Python] 12
6 Альтернативные и продвинутые визуализации (борьба с перегрузкой) 13
6.1 Шестиугольное бинирование (Hexbin Plot) и график плотности (Density Plot) [трек ML: Taipy/Python] 13
6.2 Диаграмма Санки (Sankey Diagram) [Универсально: Qlik, Taipy] 14
6.3 Точечная диаграмма категорий (Dot Plot) [Универсально: Qlik, Taipy] 15
6.4 Пузырьковая диаграмма (Bubble Chart) [Универсально: Qlik, Taipy] 16
Список источников 18
Приложение А – Глоссарий типов диаграмм и их синонимов 19

Введение

Рекомендации разработаны для курса «Интеллектуальный анализ и визуализация данных», в котором в качестве единой предметной области используется сквозной датасет сортировки (триажа) алертов SIEM аналитиками центра мониторинга информационной безопасности (SOC). Использование представленных методических рекомендаций позволяет связать технический инструментарий Data Science (метрики, распределения, объяснимый ИИ) с принципами информационного дизайна (минимизация когнитивной нагрузки, отсутствие визуального шума).

В современной практике Data Science и BI недостаточно построить модель или выгрузить сырые метрики из базы данных. Ключевой навык специалиста – донести результаты анализа или работы предиктивной модели до стейкхолдеров (руководителя SOC, инженеров ИБ, бизнес-заказчиков) без искажений и избыточной когнитивной нагрузки.

Если классический дизайн-подход [1] отвечает на вопрос *«Как очистить график от мусора и рассказать историю?»*, то настоящие рекомендации сфокусированы на инженерном вопросе: *«Какой именно математический или статистический график выбрать для конкретной задачи, и когда его использование категорически противопоказано?»*.

В профессиональной литературе и интерфейсах BI-систем названия диаграмм / графиков часто переводятся по-разному или подменяются профессиональным жаргоном. В этой связи в Приложение А приведена таблица соответствий для устранения когнитивной путаницы.

1 Ресурсы по визуализации данных

Тема выбора визуализаций обширна и не ограничивается базовым набором графиков. Для расширения насмотренности и поиска нестандартных решений рекомендуем опираться на следующие профессиональные ресурсы:

1. **Коллекция визуализаций Датайога** (https://datayoga.ru/vizcards#catalogue) – русскоязычный каталог. Позволяет задавать вопросы к данным и подбирать визуализации под задачи. Содержит описания типов сравнения данных, плюсов и минусов каждой визуализации с тщательно подобранными советами.
2. **Data Viz Project by Ferdio** (https://datavizproject.com) – коллекция Копенгагенского агентства инфографики из 154 типов визуализаций. Содержит описание и примеры реализации. Интерактивные фильтры по типу исходных данных, геометрии и функции.
3. **Financial Times Visual Vocabulary** (https://www.ft.com/vocabulary) – руководство от команды визуальной журналистики Financial Times. Представляет собой систематизированный набор типов диаграмм, сгруппированных по категориям задач: отклонение, корреляция, ранжирование, распределение, изменение во времени, величина, часть-целое, пространственные данные и потоки. Помогает выбирать оптимальную визуализацию в зависимости от истории, которую нужно рассказать с помощью данных.
4. **From Data to Viz** (https://www.data-to-viz.com) – интерактивный ресурс, представляющий собой дерево решений для выбора типа визуализации на основе формата входных данных. Классифицирует диаграммы по типу данных (числовые, категориальные и т.д.) и количеству переменных. Каждый тип диаграммы сопровождается описанием, включая типичные ошибки и предостережения. Содержит около 40 типов диаграмм и предоставляет примеры кода для реализации.
5. **Data Viz for Nonprofits** (https://nonprofitviz.com/data-tip-index-1) – структурированный каталог из более чем 200 коротких (60-секундных) советов по работе с данными, сгруппированных по тематическим категориям: применение данных к действиям, лучшие практики визуализации, дизайн дашбордов, работа с аудиторией и другие. Каждый совет содержит конкретные, прикладные рекомендации – от выбора типа диаграммы до настройки осей и адаптации визуализаций.
6. **Qlik Sense Visualization Showcase** (https://explore.qlik.com/details/qlik-sense-visualization-showcase) – профильный ресурс для трека BI-аналитики. Отражает лучшие практики и ограничения платформы Qlik.

7. **Taipy Gallery** (https://docs.taipy.io/en/latest/gallery/) – профильный ресурс для трека ML-инжиниринга. Галерея интерактивных Data-приложений и дашбордов на основе Python-фреймворка Taipy.

2 Базовый алгоритм выбора диаграммы

Базовый выбор начинается с вопроса «Что вы хотите показать?» и различает сравнение, распределение, состав и связи (Рисунок 2.1). В ветви состава и формирования итога уточните задачу: статические доли — столбцы долей или 100%-ная диаграмма с накоплением (круговая допустима для немногих простых долей); накопление аддитивных вкладов либо последовательных изменений от начального значения к итогу — Waterfall; распределение объёма между связанными категориями — Sankey. Эти типы не взаимозаменяемы. Для Sankey нужны объёмы связей; время и переходы состояний не обязательны. Например: состав вердиктов — доли; изменение очереди алертов — Waterfall; правило SIEM → вердикт — Sankey.



Рисунок 2.1 – Дерево принятия решений по выбору диаграммы

3 Матрица выбора специфических диаграмм Data Science

Таблица 3.1 систематизирует правила выбора продвинутых визуализаций.

Таблица 3.1 – Матрица выбора диаграмм (зачем и когда не использовать)

Визуализация	Зачем	Когда НЕ использовать
Гистограмма (Histogram)	Быстро оценить форму распределения, асимметрию и выбросы.	Когда нужен точный и сглаженный вид плотности, а не бининг.
Квантиль-квантильный график (QQ Plot)	Проверить, насколько данные близки к эталонному распределению.	Когда требуется сравнение категорий или зависимостей.
График оценки плотности ядра (KDE Plot)	Показать сглаженную плотность распределения.	Когда важны реальные частоты по бинам или выборка слишком мала.
Скрипичная диаграмма (Violin Plot)	Сравнить распределения по группам, сохранив форму, медиану и разброс.	Когда групп мало и важнее показать отдельные наблюдения.
ROC-кривая (ROC Curve)	Оценить классификатор при разных порогах.	Недостаточна как единственная оценка при редком положительном классе: дополнить PR и показателями рабочего порога.
Кривая точности-полноты (PR Curve)	Показать Precision против Recall при разных порогах; дополнить ROC при редком положительном классе.	Не сравнивать напрямую выборки с разной долей положительного класса; одна PR-кривая не заменяет оценку рабочего порога.
График значений Шепли (SHAP Plot)	Объяснить вклад признаков в предсказание модели.	Когда нужна только общая метрика качества без интерпретации.
График частичной зависимости (PDP)	Интерпретировать маргинальное влияние признаков на предсказание.	Когда признаки сильно коррелируют (искажается интерпретация).
График смещения-дисперсии (Bias-Variance Plot)	Понять компромисс между недообучением и переобучением модели.	Когда нужен прямой диагноз по самим данным, а не по сложности модели.
Точечная диаграмма (Dot Plot)	Сравнить категориальные значения компактнее, чем столбчатой диаграммой.	Когда визуальная длина столбца критична для точного восприятия.
Пузырьковая диаграмма (Bubble Chart)	Показать три переменные сразу: *x*, *y* и размер.	Когда третья переменная плохо считывается или точки сильно перекрываются.
Диаграмма Санки (Sankey Diagram)	Показать объёмы связей между категориями, в том числе в статическом срезе.	Известны только доли категорий, но не объёмы связей; нужен простой график долей.
Шестиугольное бинирование (Hexbin Plot)	Заменить перегруженную диаграмму рассеяния при десятках тысяч точек.	Когда точек мало и нужен прямой просмотр отдельных наблюдений.
Облачная диаграмма распределения (Raincloud Plot)	Совместить форму распределения, статистику и сырые данные по группам.	Когда нужен максимально простой график без сложной композиции.

Ниже приводится систематизированный свод правил выбора визуализаций[1] для задач разведочного анализа (EDA), оценки качества моделей машинного обучения (ML) и объяснимого ИИ (XAI).

4 Исследовательский анализ данных (EDA) и проверка распределений

Этот блок важен для этапа подготовки данных (особенно в треке BI-аналитики) при первичном исследовании датасета iavd_incidents_raw.

[1] Примеры основаны на материалах [2–6].

4.1 Гистограмма (Histogram) [Универсально: Qlik, Taipy]

Зачем использовать: быстро оценить форму распределения числовой переменной, выявить асимметрию и выбросы.
Когда НЕ использовать: когда требуется точный и сглаженный вид плотности распределения, а не дискретный бининг (группировка по интервалам).
Проекция на SOC: анализ распределения времени реакции аналитика на критические инциденты. Позволяет увидеть «хвосты», например, алерты, висящие без ответа часами.

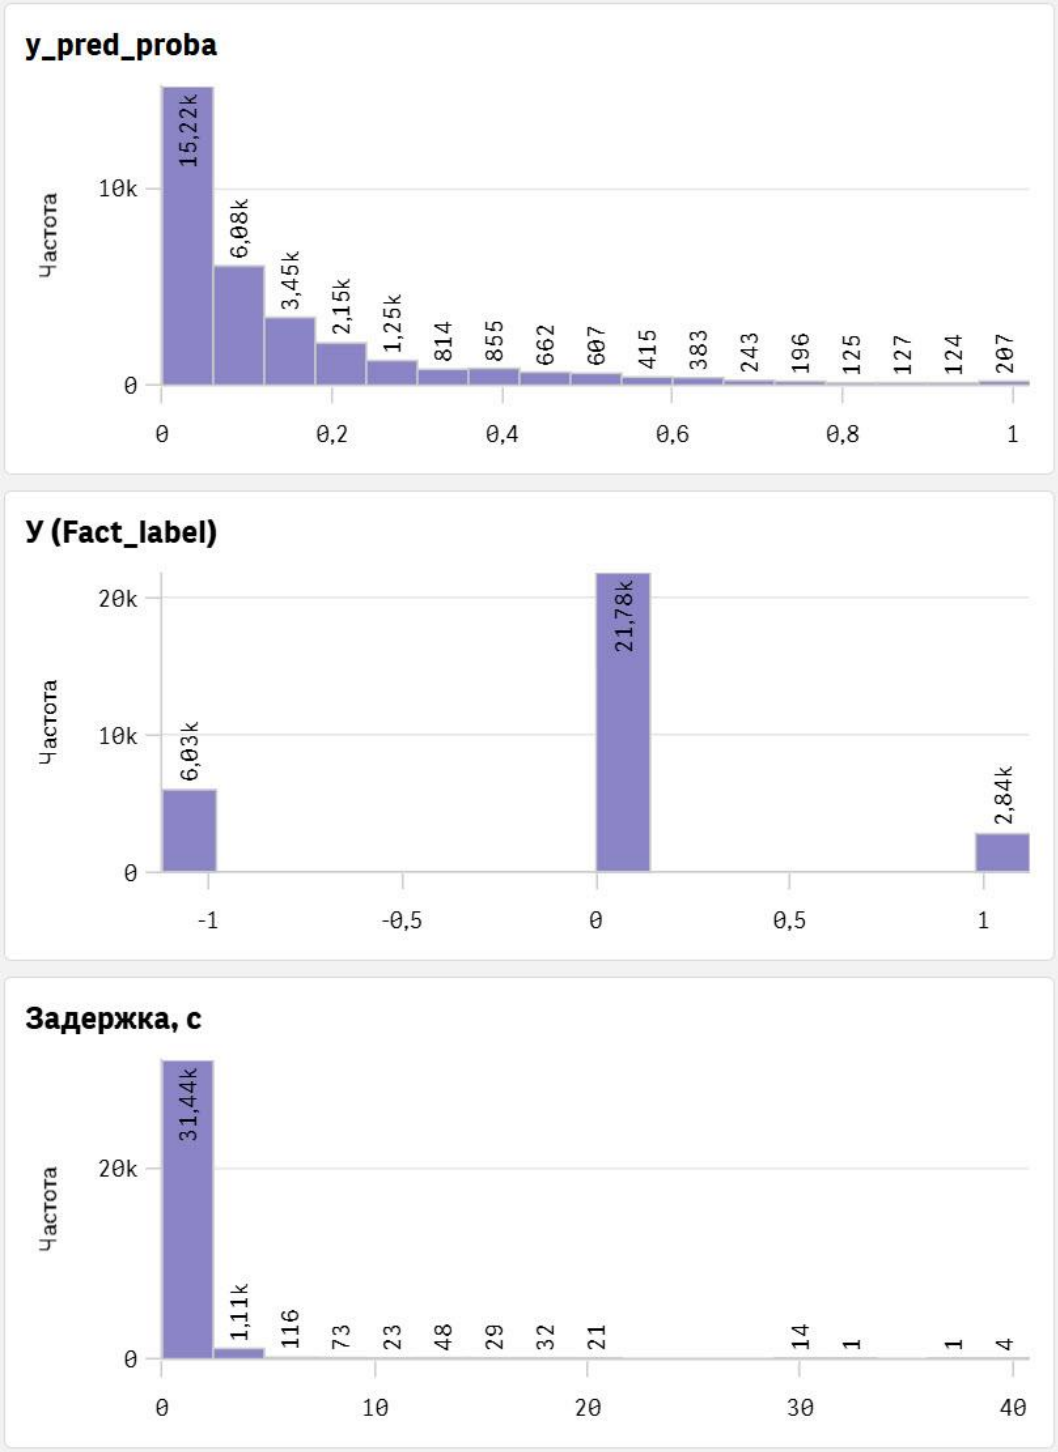


Рисунок 4.1 – Примеры гистограмм, сгенерированных на датасете SOC

4.2 Квантиль-квантильный график (QQ Plot) [трек ML: Taipy/Python]

Зачем использовать: проверить, насколько эмпирические данные близки к нормальному или другому эталонному распределению.

Когда НЕ использовать: когда требуется сравнение категорий или поиск корреляционных зависимостей между признаками, а не анализ законов распределения.

Применение в SOC: проверка гипотезы о нормальном распределении сетевого трафика или интенсивности поступления алертов для настройки статических порогов срабатывания SIEM.

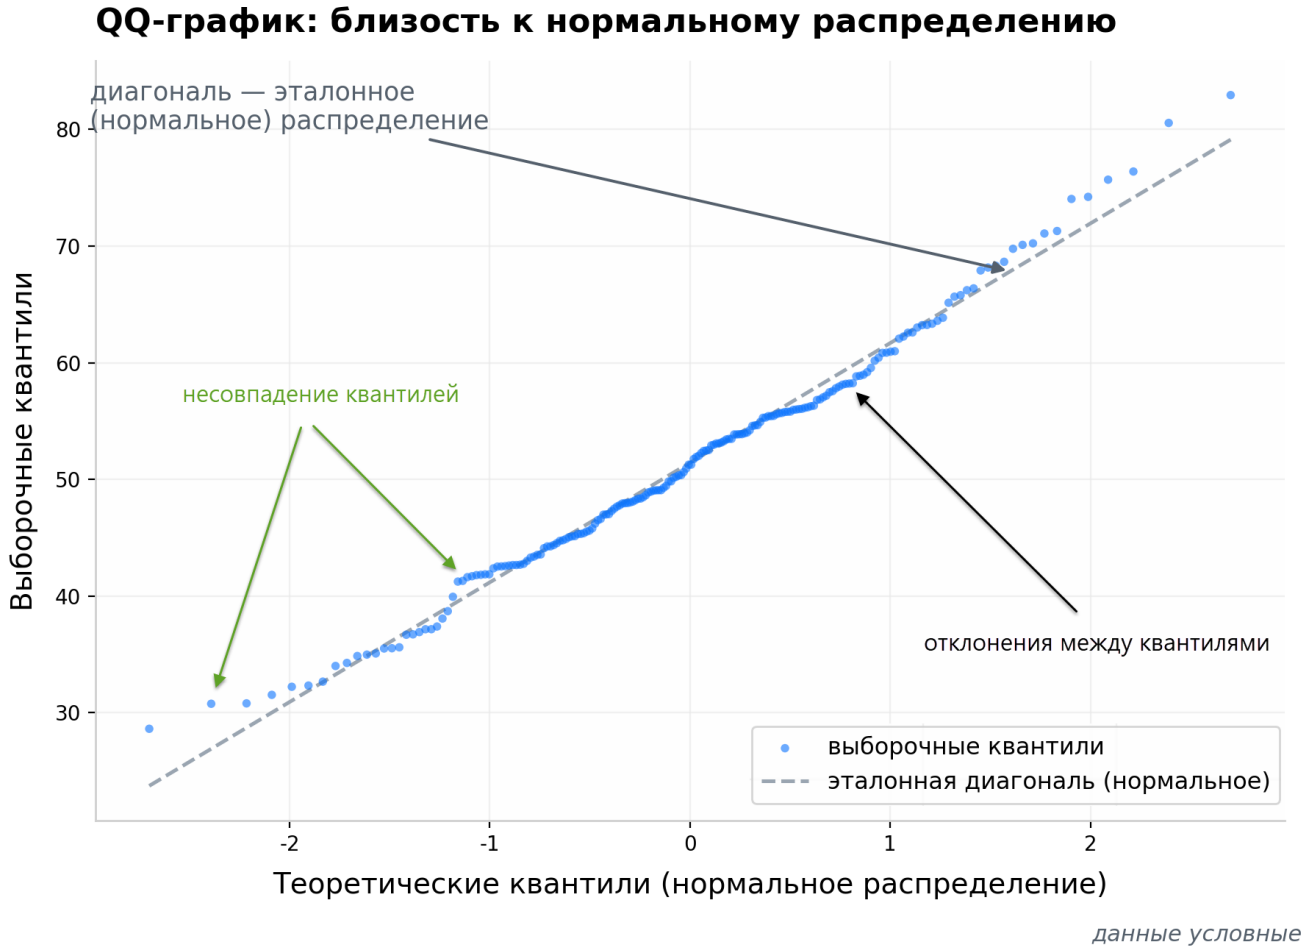


Рисунок 4.2 – Пример QQ Plot

4.3 График оценки плотности ядра (KDE Plot) [трек ML: Taipy/Python]

Зачем использовать: показать сглаженную непрерывную плотность вероятности распределения признака.

Когда НЕ использовать: когда критически важны реальные абсолютные частоты по бинам (интервалам) или когда малый размер выборки делает сглаживание математически обманчивым.

Применение в SOC: сглаженная оценка распределения вероятностей появления вредоносной активности в разное время суток или появления инцидентов в зависимости от длины командной строки (CMDLINE).

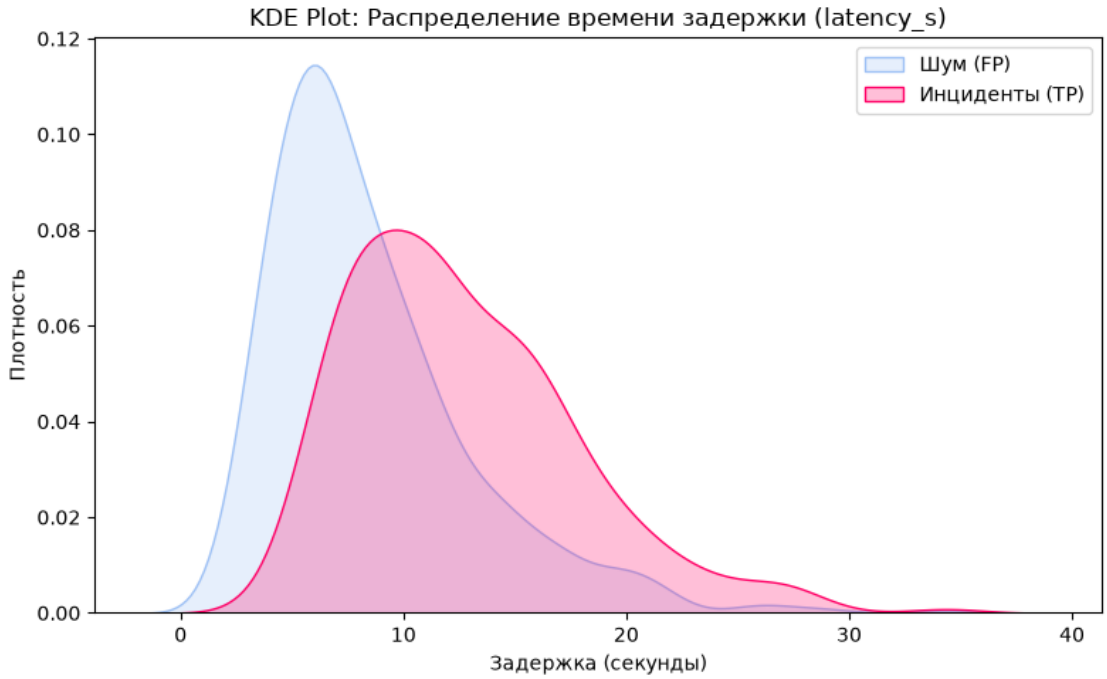


Рисунок 4.3 – KDE Plot, сгенерированный на датасете SOC

4.4 Скрипичная диаграмма (Violin Plot) [трек ML: Taipy/Python]

Зачем использовать: сравнить распределения непрерывной переменной по нескольким группам/категориям, одновременно сохранив информацию о форме распределения (внешний контур) и медиане/квантилях (внутренний box plot).
Когда НЕ использовать: когда групп крайне мало и важнее показать точечно каждое отдельное наблюдение (в этом случае лучше использовать точечную диаграмму категорий (Dot Plot) или Stripplot).
Применение в SOC: сравнение распределения критичности инцидентов (Критичность) в разрезе различных групп пользователей (suser) или источников (src).

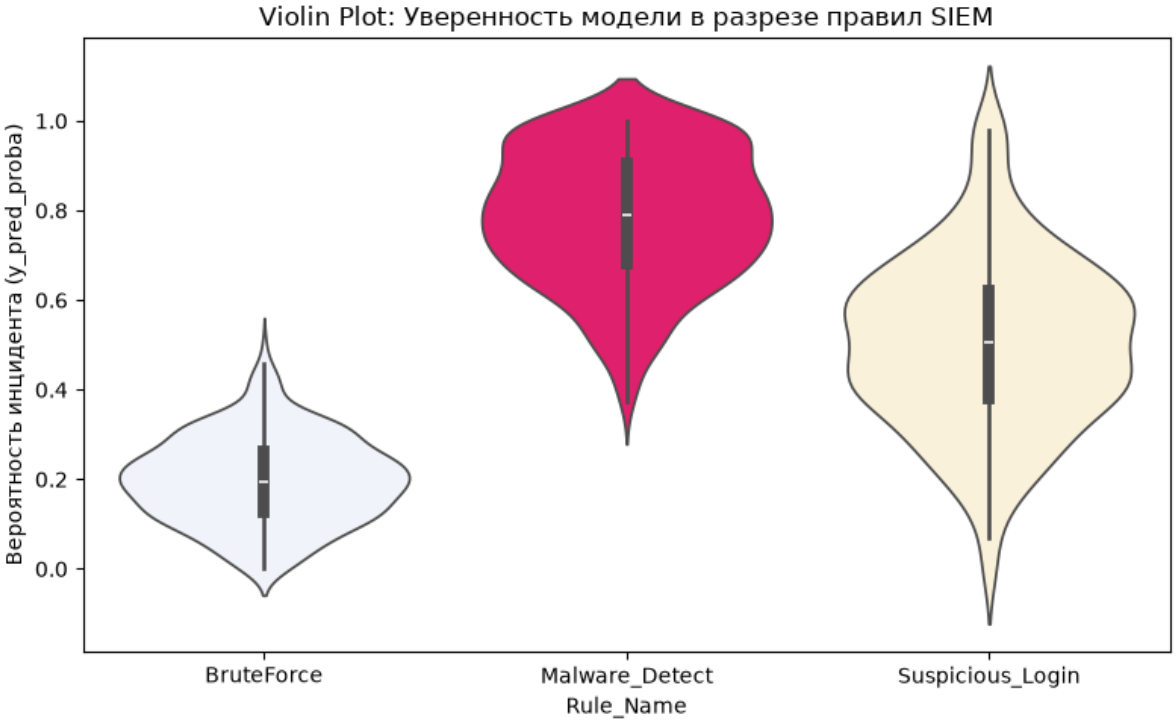
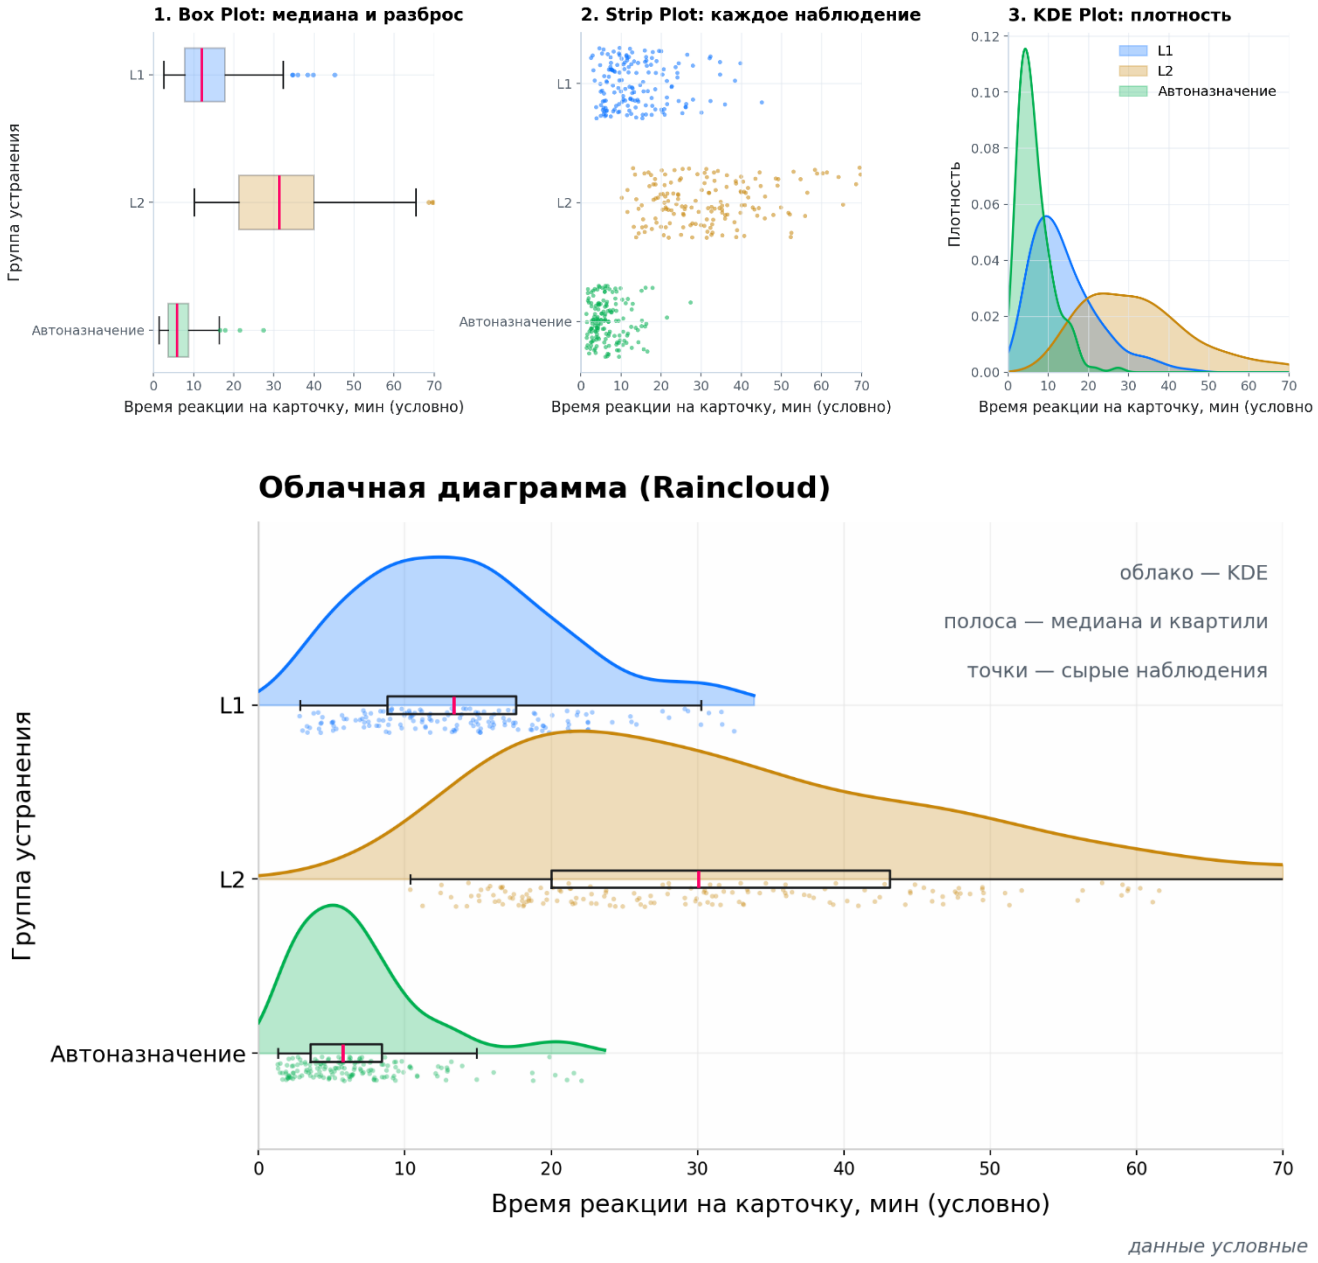


Рисунок 4.4 – Violin Plot = KDE+Box Plot, сгенерированный на датасете SOC

4.5 Облачная диаграмма распределения (Raincloud Plot) [трек ML: Taipy/Python]

Зачем использовать: Продвинутая гибридная визуализация. Совмещает «облако» (сглаженное распределение KDE), «дождь» (сырые точки данных - jitter) и «зонтик» (стандартный box plot). Обеспечивает максимальную прозрачность данных.
Когда НЕ использовать: когда требуется максимально простой график без сложной композиции (может перегрузить бизнес-пользователя).
Проекция на SOC: Глубокий анализ аномалий в поведении конкретных пользователей (suser) при расследовании инцидентов.




```
import ptitprince as pt
pt.RainCloud(data,
             x="temp",
             y="city", ...)
```

Рисунок 4.5 – Пример облачной диаграммы распределения (Raincloud Plot)

5 Оценка качества ML-моделей и объяснимый ИИ (XAI)

Этот блок является ядром для трека ML-инжиниринга (модуль 3). Модель выступает в роли советника аналитика SOC, и её поведение должно быть измеримым и интерпретируемым.

5.1 ROC-кривая vs. Кривая точности-полноты (PR Curve) [Универсально: Qlik, Taipy]

Зачем использовать:

- *ROC Curve* — TPR = TP/(TP + FN) против FPR = FP/(FP + TN) при разных порогах. Допустима при дисбалансе: сам дисбаланс при неизменных распределениях скора внутри классов не делает ROC «идеальной» и не улучшает ROC AUC;
- *Precision-Recall Curve* — *Precision* = TP/(TP + FP) против Recall = TP/(TP + FN). PR дополняет ROC при редком положительном классе. Дисбаланс описывается $N_+ \ll N_-$, где $N_+ = TP + FN$ — фактически положительные объекты, $N_- = FP + TN$ — фактически отрицательные. Это не отношение TP к FP. Долю атак определяют по истинным меткам на оценочной выборке: в отобранных карточках SIEM она может отличаться от доли в полном потоке событий.

Когда НЕ использовать:

- нельзя ограничивать оценку одной ROC/AUC: низкий FPR на большом отрицательном классе может сочетаться с большим числом FP и низкой Precision. Учебная рабочая точка: $N_+ = 100$, $N_- = 100\,000$; TP = 80, FN = 20, FP = 1 000, TN = 99 000. Recall = 80 %, FPR = 1 %, Precision = 80/1 080 ≈ 7,4 %. Это одна точка порога, а не значение всей ROC AUC;
- PR не использует TN напрямую, но зависит от доли положительного класса. Сравнивайте модели на сопоставимых выборках; одна PR-кривая также не заменяет показатели рабочего порога.

Применение в SOC: сопоставьте предсказания модели с истинными метками Fact_label. Вместе с ROC/AUC и PR покажите Precision, Recall, абсолютные FP/FN рабочего порога за заданный период, цену ошибок и ограничения нагрузки SOC. KPI макета 99 387/184 186 ≈ 54 % — доля карточек с операционным вердиктом FP, не FPR модели и не доля трудозатрат SOC. Операционные вердикты и ошибки модели различаются; для трудозатрат нужны длительности обработки карточек.

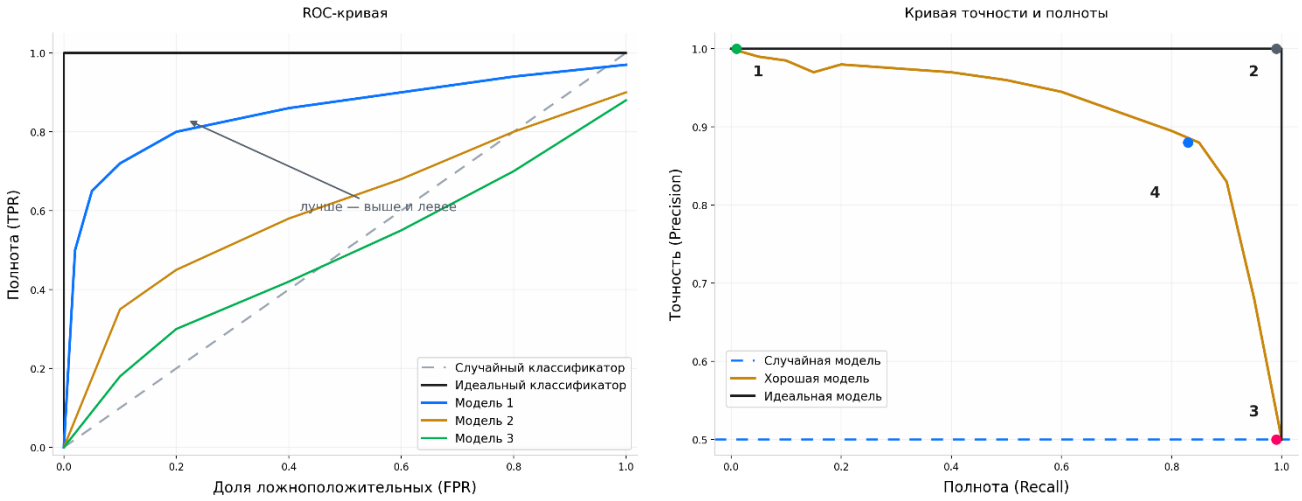


Рисунок 5.1 – Схематические ROC и PR из источника [4] (не одна модель; базовая линия PR равна доле положительного класса)

5.2 График значений Шепли (SHAP Summary / Waterfall Plot) [трек ML: Taipy/Python]

Зачем использовать: объяснить вклад (величину и направление) конкретных признаков (CMDLINE, processName) в итоговое предсказание модели глобально (Summary) или локально для одной карточки (Waterfall).
Когда НЕ использовать: когда требуется исключительно общая метрика качества модели (например, Accuracy или F1-score) без требования интерпретируемости «черного ящика».
Применение в SOC: вывод аналитику визуальной подсказки: почему модель считает данный процесс атакой (например, красная полоска SHAP показывает, что наличие флага -enc в Powershell сильно сдвинуло y_pred_proba к 1).

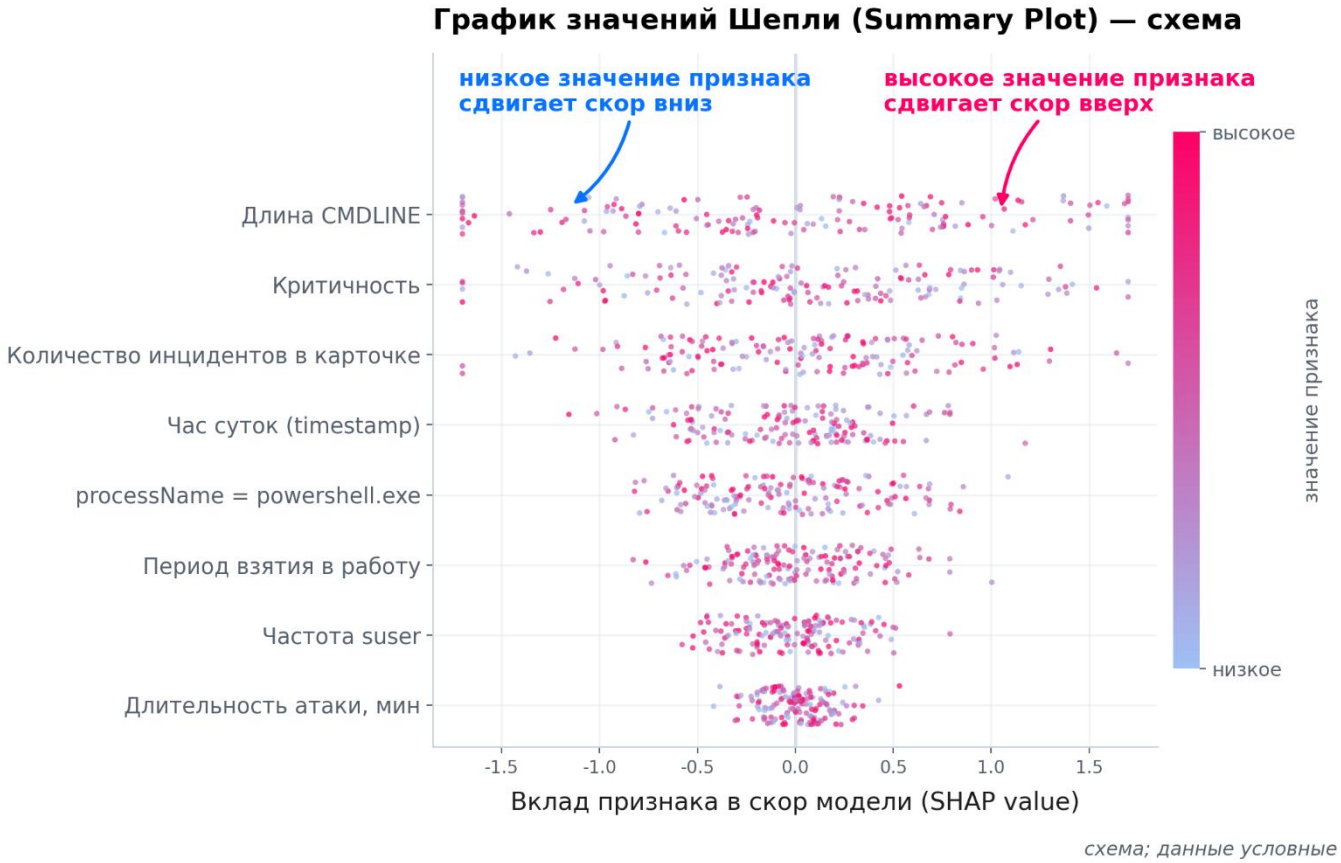


Рисунок 5.2 – Пример SHAP Plot

5.3 График частичной зависимости (Partial Dependence Plot (PDP))

Зачем использовать: интерпретировать маргинальное (изолированное) влияние одного или двух признаков на предсказание модели-советника.
Когда НЕ использовать: когда входные признаки сильно мультиколлинеарны (например, размер переданных данных и количество пакетов). В этом случае PDP вычисляет вероятности для нереалистичных комбинаций признаков, искажая картину.
Применение в SOC: оценка того, как плавное увеличение энтропии командной строки влияет на рост уверенности модели в том, что перед нами обфусцированный вредонос.

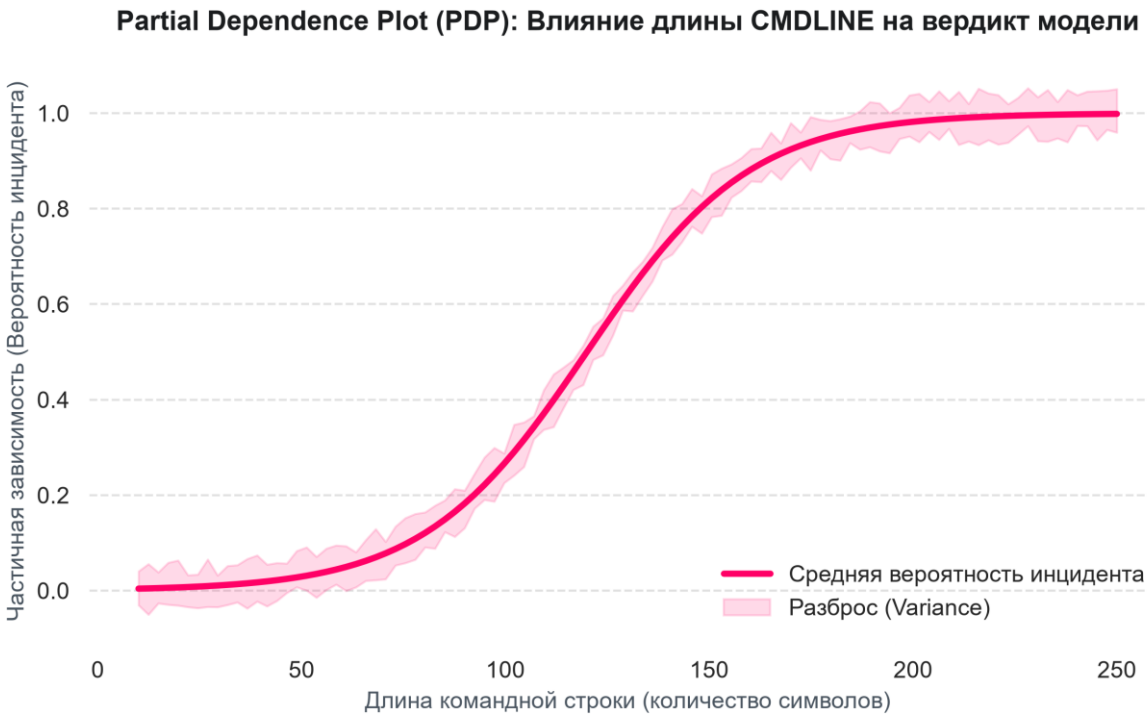


Рисунок 5.3 – График частичной зависимости (PDP), сгенерированный на датасете SOC

5.4 График смещения-дисперсии (Bias-Variance Plot) [трек ML: Taipy/Python]

Зачем использовать: понять компромисс между недообучением (высокий Bias) и переобучением (высокая Variance) при настройке гиперпараметров модели (например, глубины деревьев).
Когда НЕ использовать: когда нужен прямой диагноз по самим данным (качество признаков), а не по сложности архитектуры модели.
Проекция на SOC: обоснование выбора сложности ML-модели-советника: слишком сложная модель выучит специфичный шум конкретных серверов (переобучение), слишком простая – пропустит очевидные атаки.

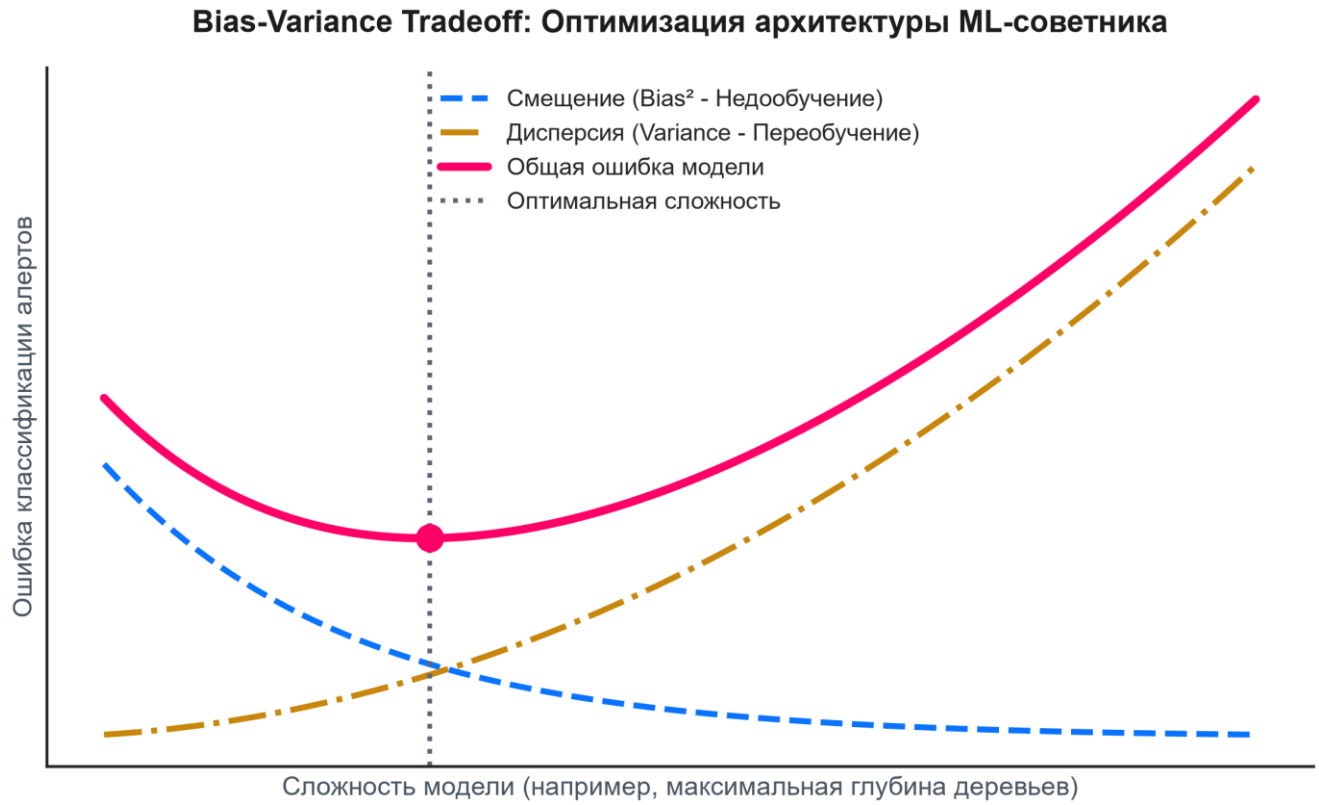


Рисунок 5.4 – Пример графика смещение-дисперсия (Bias-Variance Plot), сгенерированный на датасете SOC

6 Альтернативные и продвинутые визуализации (борьба с перегрузкой)

Методические рекомендации этого раздела призваны обеспечить создание чистых, читаемых дашбордов.

6.1 Шестиугольное бинирование (Hexbin Plot) и график плотности (Density Plot) [трек ML: Taipy/Python]

Зачем использовать: заменить перегруженную диаграмму рассеяния (scatter plot), которая превращается в сплошное пятно при работе с десятками тысяч точек данных. Hexbin показывает плотность распределения цветом сот/ячеек.
Когда НЕ использовать: когда точек в датасете мало (<100) и критически важно видеть позиционирование каждого отдельного объекта (например, инцидентов) без агрегации.
Проекция на SOC: анализ связи между временем суток и количеством сгенерированных алертов на большом исторических массиве (iavd_incidents_raw).

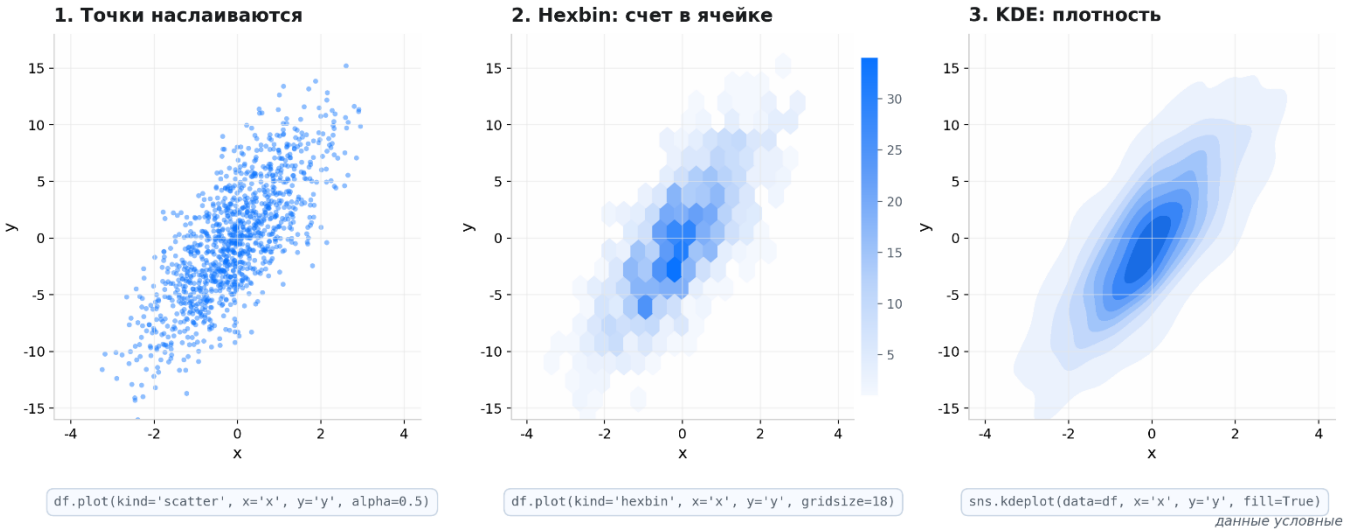


Рисунок 6.1 – Сравнение Scatter, Hexbin и Density из источника [1]

6.2 Диаграмма Санки (Sankey Diagram) [Универсально: Qlik, Taipy]

Зачем использовать: показать распределение объёма между связанными категориями. Например, ленты между предсказанием модели и истинной меткой отражают количества TP, FP, FN и TN, а не переходы объекта во времени. Sankey может показывать статический срез; время и смена состояний не обязательны.
Когда НЕ использовать: когда известны только доли отдельных категорий, но не объёмы связей между ними, либо нужен простой график статических долей.
Проекция на SOC: визуализация матрицы ошибок (Confusion Matrix) (Рисунок 6.2) датасета model_assessment как потоки в диаграмме Санкей (Sankey Diagram) (Рисунок 6.3).



Рисунок 6.2 – Пример матрицы ошибок (Confusion Matrix)

Слева – фактическая разметка (Fact_label), справа – предсказания модели (y_pred = 0 или 1). Ширина потоков перекрестий покажет объемы FP и FN

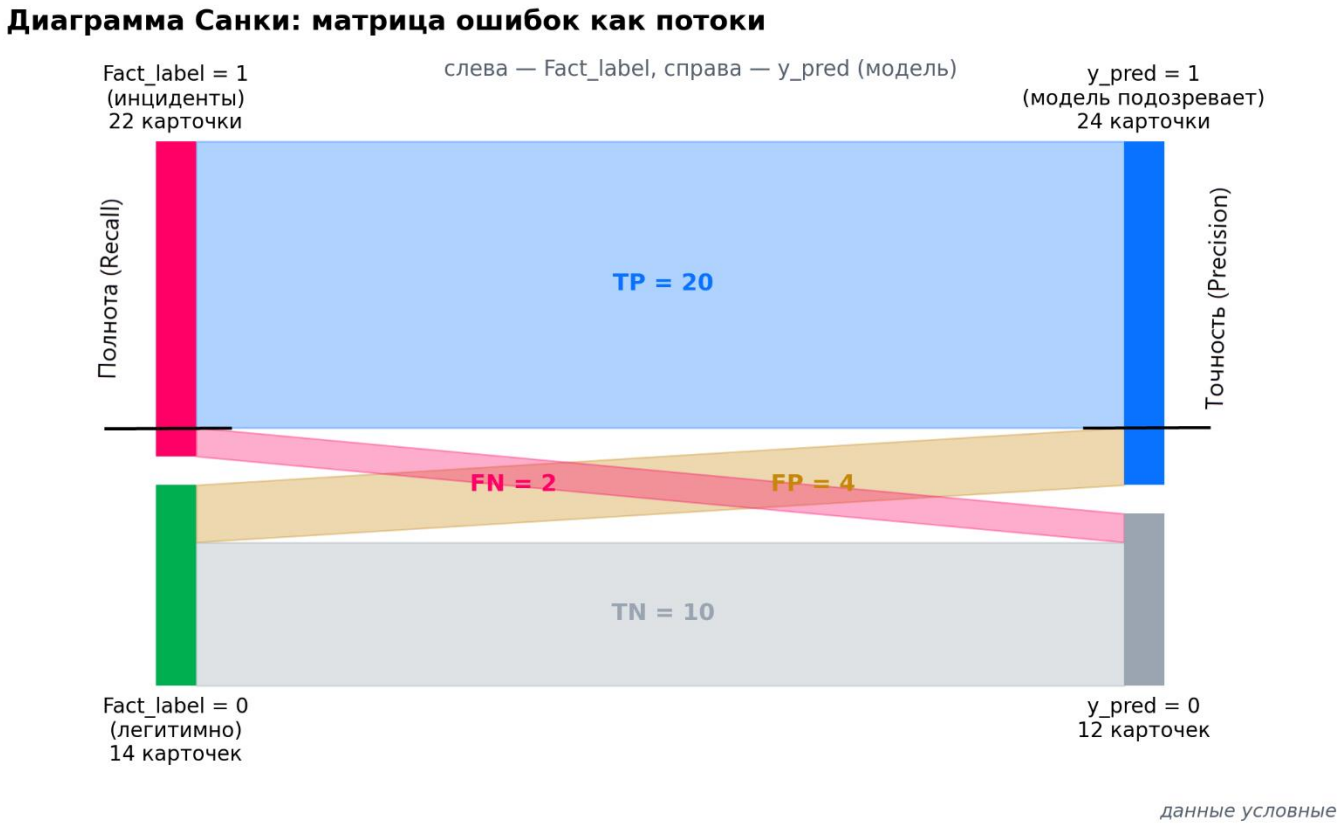


Рисунок 6.3 – Пример даграммы Санкей (Sankey Diagram)

6.3 Точечная диаграмма категорий (Dot Plot) [Универсально: Qlik, Taipy]

Зачем использовать: сравнить категориальные значения компактнее и «чище», чем столбчатой диаграммой (bar chart), максимизируя *Data-ink ratio* (убирая тяжелые заливки столбцов).

Когда НЕ использовать: когда визуальная длина или площадь столбца критична для точного интуитивного восприятия разницы нетренированным глазом.

Проекция на SOC: топ-20 IP-адресов источников (src) по количеству сгенерированных алертов. Выглядит компактно и не перегружает дашборд массивными цветными блоками.

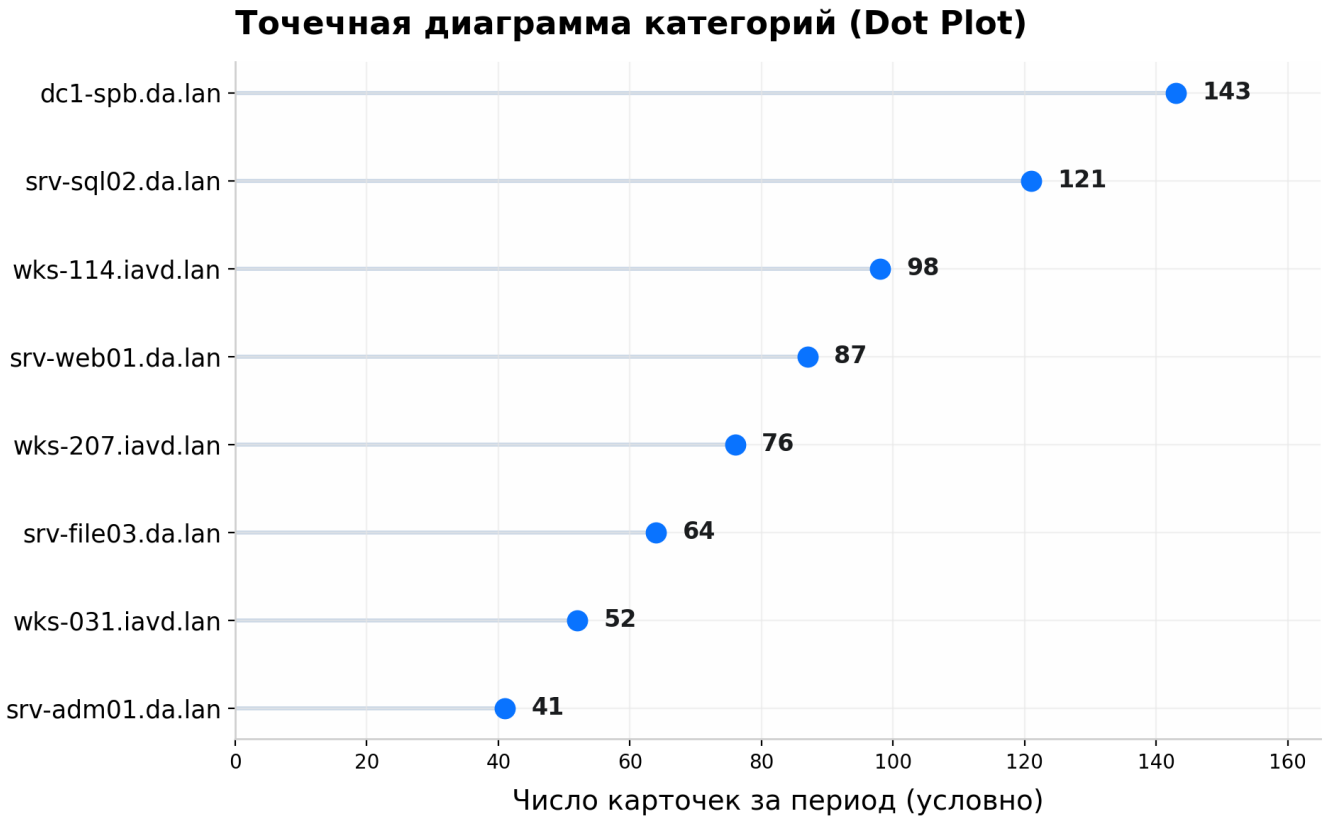


Рисунок 6.4 – Сравнение Bar Chart и Dot Plot из источника [1]

6.4 Пузырьковая диаграмма (Bubble Chart) [Универсально: Qlik, Taipy]

Зачем использовать: показать зависимость сразу переменных: оси *X*, *Y* и размер пузырька.
Когда НЕ использовать: когда разница в значениях третьей переменной (размере) минимальна и не считывается глазом, либо если пузырьки сильно перекрывают друг друга.
Проекция на SOC: *X* – время расследования алерта, *Y* – количество сработавших правил, *Размер* – риск-скор (критичность).

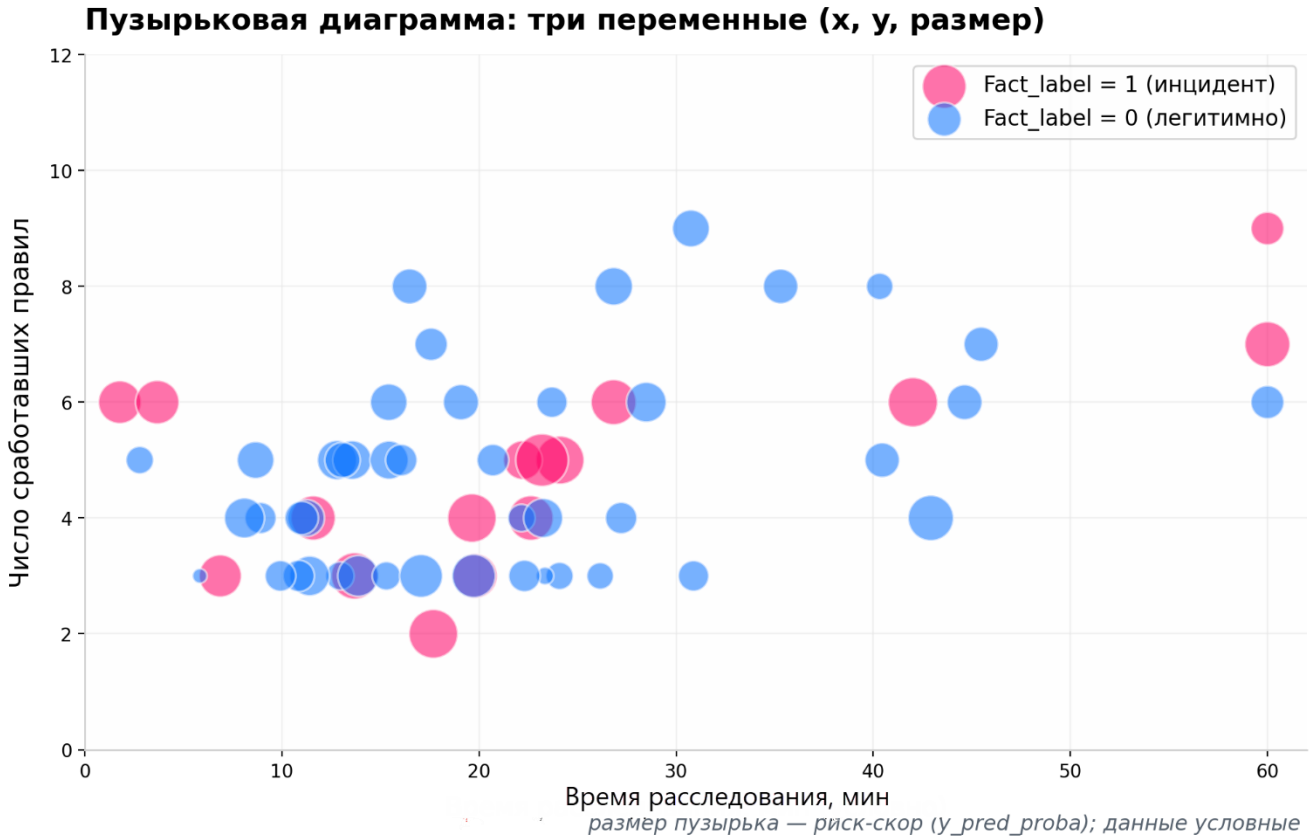


Рисунок 6.5 – Пример Bubble Chart из источника [1]

Список источников

1. Нафлик, Коул Нассбаумер. Данные: визуализируй, расскажи, используй. Сторителлинг в аналитике / Коул Нассбаумер Нафлик ; пер. с англ. Ю. Константиновой ; [науч. ред. С. Шабалкина]. – М. : Манн, Иванов и Фербер, 2025. – 280 с. : ил.
2. **Chawla, A.** 8 альтернатив традиционным графикам в Data Science [Электронный ресурс] / A. Chawla // Daily Dose of Data Science. – URL: https://www.dailydoseofds.com/p/8-alternatives-to-traditional-plots/ (дата обращения: 03.08.2026).
3. **Chawla, A.** 11 способов определения нормальности данных [Электронный ресурс] / A. Chawla // Daily Dose of Data Science. – URL: https://blog.dailydoseofds.com/p/11-ways-to-determine-data-normality (дата обращения: 03.08.2026).
4. **Chawla, A.** 9 важнейших графиков в Data Science [Электронный ресурс] / A. Chawla // Daily Dose of Data Science. – URL: https://blog.dailydoseofds.com/p/9-most-important-plots-in-data-science (дата обращения: 03.08.2026).
5. **Chawla, A.** 11 важнейших графиков для Data Science [Электронный ресурс] / A. Chawla // Daily Dose of Data Science. – URL: https://blog.dailydoseofds.com/p/11-most-important-ds-plots (дата обращения: 03.08.2026).
6. **Chawla, A.** Руководство по визуализации с использованием диаграмм Санки [Электронный ресурс] / A. Chawla // Daily Dose of Data Science. – URL: https://blog.dailydoseofds.com/p/a-visualisation-guide-on-sankey-diagrams (дата обращения: 03.08.2026).

Приложение А – Глоссарий типов диаграмм и их синонимов

В приложении приведена Таблица А.1 соответствий для устранения когнитивной путаницы в связи с различиями в переводе названия графиков или подменой их профессиональным жаргоном.

Таблица А.1 – Типы диаграмм и их синонимы

Каноничное название (RU)	Оригинал (EN)	Синонимы и сленг (RU / EN)	Основное назначение
Столбчатая диаграмма	Bar Chart / Column Chart	Барчарт, гистограмма (ошибочно)	Сравнение категорий по количественному показателю
Линейчатая диаграмма	Horizontal Bar Chart	Горизонтальный барчарт	Сравнение длинных названий категорий
Гистограмма	Histogram	Распределение частот, биннинг	Оценка формы распределения непрерывной величины
Линейный график	Line Chart / Line Graph	График динамики, таймлайн	Показ тенденций и изменений во времени
Диаграмма рассеяния	Scatter Plot	Точечный график, скаттер-плот	Выявление корреляций и связи между двумя переменными
Круговая диаграмма	Pie Chart	Диаграмма-торт, секторная	Показ структуры (долей) целого (не рекомендуется)
Кольцевая диаграмма	Donut Chart	Диаграмма-пончик	Аналог круговой диаграммы со свободным центром
Диаграмма размаха	Box Plot	Ящик с усами, box-and-whisker	Компактный показ медианы, квантилей и выбросов
Скрипичная диаграмма	Violin Plot	Виолин-плот	Совмещение диаграммы размаха и графика плотности
Тепловая карта	Heatmap	Хитмап, матрица плотности	Кодирование интенсивности значений с помощью цвета
Каскадная диаграмма	Waterfall Chart	Водопад, диаграмма моста	Показ пошагового накопления итогового значения
График плотности	KDE Plot / Density Plot	Сглаженная гистограмма	Непрерывная оценка плотности распределения